

Atividade 01:

1. Explique, com suas palavras, o que é machine learning?

Machine learning é uma área da inteligência artificial em que, ao invés de programarmos regras fixas para o computador seguir, nós damos a ele uma quantidade grande de dados e deixamos que ele mesmo identifique padrões e "aprenda" a partir disso. Por exemplo, ao invés de escrever um código com centenas de regras para reconhecer se um e-mail é spam, é fornecido milhares de exemplos de e-mails já classificados como spam ou não spam, e o algoritmo aprende sozinho quais características costumam indicar spam. Depois desse aprendizado, ele consegue fazer previsões sobre dados novos que nunca viu antes.

2. Explique o conceito de conjunto de treinamento, conjunto de validação e conjunto de teste em machine learning.

Esses três conjuntos servem para garantir que o modelo realmente aprendeu de forma generalizada, e não decorou os dados.

- **Conjunto de treinamento:** é a maior parte dos dados, usada para o modelo efetivamente aprender os padrões, ajustando seus parâmetros internos.
- **Conjunto de validação:** é usado durante o desenvolvimento para ajustar hiperparâmetros e comparar diferentes versões do modelo, servindo como uma espécie de "teste intermediário" antes de decidir a versão final.
- **Conjunto de teste:** é usado só no final, com dados que o modelo nunca viu em nenhuma etapa anterior, para avaliar de forma justa e realista o desempenho dele.

Se fosse usado o mesmo conjunto de dados para treinar e avaliar o modelo, eu não saberia se ele realmente aprendeu algo útil ou só "decorou" as respostas,

3. Explique como você lidaria com dados ausentes em um conjunto de dados de treinamento.

Depende muito do contexto e da quantidade de dados faltantes. Primeiro eu analisaria o quanto de dado está ausente e se existe algum padrão nessa ausência (por exemplo, se falta em uma coluna inteira ou está espalhado aleatoriamente). Algumas estratégias que eu usaria:

- Se a proporção de valores ausentes for pequena, posso simplesmente remover as linhas ou colunas afetadas.
- Se for uma quantidade maior, posso preencher os valores com a média, mediana ou moda da coluna, dependendo do tipo de dado.
- Em casos mais complexos, dá pra usar técnicas de imputação mais sofisticadas, como prever o valor ausente com base em outras variáveis correlacionadas, ou usar algoritmos que já lidam nativamente com valores ausentes.

O importante é entender o porquê da ausência antes de decidir a abordagem, porque isso pode indicar algo relevante sobre os dados (por exemplo, se um sensor falhou ou se determinada informação simplesmente não se aplica àquele registro).

4. O que é uma matriz de confusão e como ela é usada para avaliar o desempenho de um modelo preditivo?

A matriz de confusão é uma tabela que mostra o desempenho de um modelo de classificação, comparando os valores que ele previu com os valores reais. Ela é dividida em quatro categorias principais: verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

A partir dela, conseguimos calcular métricas importantes como acurácia, precisão, recall e F1-score. Isso é muito mais útil do que olhar só a acurácia geral, principalmente em problemas com classes desbalanceadas.

5. Em quais áreas você acha mais interessante aplicar algoritmos de machine learning?

Eu acho a área da saúde uma das mais interessantes, principalmente em diagnóstico por imagem, como detecção de anomalias em exames de ressonância, tomografia ou até imagens de retina, algo que, inclusive, tenho tido contato em projetos acadêmicos envolvendo segmentação de imagens médicas. Machine learning pode ajudar a identificar padrões sutis que passariam despercebidos pelo olho humano, agilizando diagnósticos e até salvando vidas.

Também acho a astronomia um campo muito interessante, já que os telescópios modernos geram um volume enorme de dados e imagens que seria inviável analisar manualmente. Algoritmos de machine learning são usados para classificar galáxias, detectar exoplanetas a partir de variações de luminosidade e até identificar eventos raros, como sinais de ondas gravitacionais, em meio a um mar de ruído.

Por fim, a área de jogos é interessante também. Machine learning é usado para criar NPCs com comportamento mais realista e adaptativo, ajustar a dificuldade dinamicamente de acordo com o desempenho do jogador, gerar conteúdo procedural e até detectar cheating em jogos online através de padrões anômalos de comportamento.